

电动车充电站数据整合与增强

COMP5339 项目作业 1 · 中文版

译者说明：本文件为英文项目说明的中文译文，供小组理解要求使用；如有歧义，以英文原件为准。原文链接保留为可点击链接。

在本次数据工程作业中，你们小组将获取新南威尔士州交通局（Transport for NSW）的电动车（EV）充电站数据，与澳大利亚统计局（ABS）的空间数据整合，并使用从充电运营商网站获取的充电设施详情进行增强。本项目旨在提供数据获取、整合、清洗、转换和存储等核心数据工程技能的实践经验。

这是一项小组作业，每组由 3 至 4 名学生组成。作业 1 的分组将在作业 2 中保持不变，作业 2 将以作业 1 完成的工作为基础。

两次作业分别对应两个阶段，需分别提交：

阶段 1（第 8 周）：在 2026 年 9 月 25 日星期五 23:59 前提交作业 1 的全部成果。

阶段 2（第 12 周）：作业 2 的说明将在之后提供。

所有提交内容都将接受抄袭检查。

作业 1 的任务

作业 1 重点获取和整合 NSW 电动车充电设施的静态数据集，以用于覆盖情况分析，并在作业 2 中用于价格监测。你们小组需要开发 Python 程序完成以下任务。

1. 数据获取

使用程序（Python 或 Unix 脚本）获取以下数据集：

NSW 电动车充电站位置数据，可从 [Transport for NSW 网站](#) 或 [data.gov.au](#) 获取。使用 Transport for NSW 网站需要免费注册登录。获取 2025 年 12 月发布的最新版本。

从 ABS 最新发布的《澳大利亚统计地理标准》（ASGS）获取 SA4 层级（区域级）的数字边界 shapefile：[ASGS 第 4 版（2026 年 7 月至 2031 年 6 月）数字边界文件](#)。

你们的方案应完全可复现。数据集获取必须通过脚本或 Python 自动完成，不应要求手动下载。

2. 数据整合与清洗

编写 Python 代码，对获取的数据进行预处理、清洗和合并。这可能包括转换数据类型，以及识别并处理缺失值、重复记录、命名规范不一致和充电设施属性不一致等数据质量问题。作为这一过程的一部分，还应使用 Python 或 SQL 对充电站数据与 ASGS 数据进行空间连接，为充电站增加一个字段，表示其所在的 SA4 区域。

3. 数据增强

为相当一部分电动车快充站点（充电类型为 DC，目标为 50% 或以上）补充一种或多种原始 Transport for NSW 数据集中没有的属性。例如：

插头类型；
价格信息；
运营商详情；
充电车位数量。

这一部分可以重点关注 DC 充电设施。通过 Python 程序，从对应的充电运营商网站，或其他开放 Web API（例如 Open Charge Map，甚至 Google Maps）查询相关信息。记录所使用的方法以及 API 使用情况。记录将外部数据关联到充电站点时使用的匹配策略，例如名称匹配、坐标匹配或地址匹配。保留所获取数据的本地副本（例如 CSV 格式），因为重复获取可能耗时，并且受到 API 使用限制。

4. 数据转换与存储

将经过处理和增强的数据转换为适合分析与可视化的结构化格式。具体要求如下：

设计关系型数据库结构，以支持高效存储和查询充电站位置、运营商、充电设施特征和地理区域。

实现该数据库结构，并通过程序将数据存储到 DuckDB。确保包含空间扩展，以便在作业 2 中执行空间查询（对任务 2 也有帮助）。

提供能够重新创建数据库结构的 SQL DDL 脚本。

重要说明：在项目报告中清楚论证数据库设计决策，例如选择规范化或反规范化结构的理由。若小组在使用数据库方面遇到重大困难，可以改用多个独立 CSV 文件存储数据；但选择 CSV 存储将被扣分。

5. 文档与报告

在整个项目流程中维护详细文档。最终报告应清楚总结数据获取、整合、清洗、增强以及转换/存储的方法。具体包括：

解释数据获取和预处理方法，包括充电站与 ASGS 区域之间的空间整合。

列明用于数据增强的其他 Web API 或网站来源，并说明访问方式。

提供清晰的数据库结构图，并论证设计选择。

讨论原始数据集和增强后数据集的完整性与一致性。

描述遇到的挑战及其解决办法。

建议的报告章节见下一页。

建议的报告章节

引言

数据来源与获取

数据清洗与质量评估

空间数据整合方法

数据增强方法

数据库设计

挑战与局限

团队贡献

提交成果

通过 Canvas 提交以下三项内容：

1. 源代码与数据库压缩包 (.zip)

包含脚本、Python 文件 (.py 或 .ipynb)、数据、requirements.txt 和 README.md。

按照清晰、合理的项目结构组织代码和 Python Notebook。

提供 requirements.txt，列出在干净 Python 虚拟环境中运行程序所需的全部 Python 包。

包含任务 4 的最终数据库：DDL 脚本和 DuckDB 数据库文件。选择 CSV 替代方案的小组应提交处理后的 CSV 文件。数据增强阶段获取的额外数据也可以以 CSV 文件提交。

提供 Markdown 格式的 README.md，内容包括项目结构、环境配置说明、执行说明、所作假设，以及生成的输出和所附数据文件的说明。

2. 项目报告 (.pdf)

报告应结构清晰，正文最多 6 页。封面和可选附录不计入页数限制。封面必须展示组名，并列成员姓名和 SID（学号）。建议章节参见上面的任务 5。

报告必须包含一段不超过 100 词的成员贡献说明，具体描述每位成员的贡献。例如：AXX：主导数据收集和预处理，……；BXX：开发数据库模型，……。

3. 生成式 AI (genAI) 与自动写作工具使用报告

本作业允许使用 genAI 工具，为代码和报告开发提供建议、校对或概念解释；但内容与代码的实质性部分必须由你们贡献。你们仍须负责核验所有提交内容的正确性与原创性。

必须通过提交“生成式 AI 与自动写作工具使用报告”，声明所使用的 genAI 工具。

提交截止时间

作业 1 的全部成果必须在 2026 年 9 月 25 日星期五 23:59 前提交。

迟交将根据大学政策受到处罚。

小组成员参与及评分

这是一项小组作业。请在报告中声明每位成员的参与程度（见上文“提交成果”）。同时请注意：你获得的作业分数以你在被问及时能够向辅导老师或讲师解释提交内容的任何部分为条件。

如果小组在理解内容方面遇到困难，应在 Ed 上提问；如果需要直接讨论代码或报告写作，请使用私密帖子。

贡献程度	获得小组分数的比例
没有参与。	0%
贡献较少，但至少对小组提交内容有一定理解。	50%
对小组提交内容作出主要贡献。	100%